



Département des Technologies de l'information et de la
communication (TIC)
Filière Informatique et systèmes de communication
Orientation Sécurité informatique

Rapport de recherche

Génération de vidéos IA

Étudiant

Dylan Oliveira Ramos

Enseignant responsable

Prof. Jean-Marc Bost

Année académique

2025-2026

Yverdon-les-Bains, le 23.03.2026

1 Introduction

Les modèles de génération de vidéos IA doivent permettre de générer des vidéos réalistes de personnes effectuant une vérification d'identité (regarder la caméra, tourner la tête, sourire, etc.), il en existe deux catégories :

- Text-to-Video
- Image-to-Video

Les deux génèrent des vidéos mais ce qui les différencie sont les données d'entrée nécessaires.

1.1 Text-to-Video

Les modèles de type Text-to-Video analysent le prompt et créent eux-mêmes les visuels et les mouvements à partir de zéro. Cela leur laisse beaucoup de créativité mais rend plus difficile le contrôle du résultat final, ce qui peut être problématique pour la vérification d'identité.

1.2 Image-to-Video

Les modèles de type Image-to-Video partent d'une image fournie et génèrent la séquence demandée dans le prompt. Ce type de modèle est plus contrôlable visuellement et est plus adapté à la vérification d'identité car il permet de faire correspondre le visage de la vidéo avec celui des documents d'identité s'il viennent à être demandés.

2 Choix des modèles

2.1 Critères de sélection

Plusieurs modèles de type Image-to-Video ont été analysés, les critères de sélection sont les suivants :

1. **API disponible** : une API doit être disponible pour pouvoir automatiser la génération de vidéos.
2. **Temps de vidéo** : la vidéo générée doit être suffisamment longue pour que la vérification de l'identité puisse se faire.
3. **Qualité de la vidéo** : la qualité de la vidéo doit être assez bonne pour tromper les systèmes de reconnaissance faciale.
4. **Audio** : la possibilité d'ajouter de l'audio est un plus.

À noter que le prix n'est pas mentionné dans les critères car il dépend de la qualité de la vidéo, de l'audio, etc. Celui-ci est analysé plus bas dans la Section 3.

2.2 Tableau comparatif

Service	API disponible	Temps de vidéo	Qualité de la vidéo	Audio
Veo 3.1	Oui	8s	1080p	Oui
Sora 2	Oui	15s	720p	Oui
Kling 3.0	Oui	15s	1080p	Oui
Wan 2.6	Oui	15s	1080p	Oui
Grok Imagine	Oui	15s	720p	Oui
Hailuo 2.3	Oui	10s	1080p	Non

3 Service d'API

Un service d'API est une plateforme qui regroupe les APIs des différents services de génération. Il met à disposition une API qui permet d'utiliser plusieurs modèles d'IA de manière centralisée et moins coûteuse que chez les fournisseurs directement.

3.1 Kie.ai

Le service d'API choisi est Kie.ai. Il a été choisi pour sa simplicité d'utilisation, sa documentation claire et son prix compétitif. De plus, il propose un "bac à sable" permettant de tester les APIs des modèles gratuitement et offre 80 crédits lors de l'inscription. Il regroupe également des modèles de génération d'images, ce qui peut être utile pour générer des visages et des documents d'identité.

3.2 Comparaison des prix des modèles

Les tableaux ci-dessous comparent les prix de chaque modèle dans leur configuration minimale (moins bonne qualité, plus courte durée, etc.) et maximale (meilleure qualité, durée plus longue, etc.).

3.2.1 Prix minimum

Modèle	Temps de vidéo	Qualité de la vidéo	Audio	Prix
Veo 3.1	8s	1080p	Oui	0.30\$
Sora 2	10s	720p	Oui	0.175\$
Kling 3.0	3s	720p	Non	0.10\$
Wan 2.6	5s	720p	Oui	0.35\$
Grok Imagine	6s	480p	Oui	0.05\$
Hailuo 2.3	6s	768p	Non	0.15\$

3.2.2 Prix maximum

Modèle	Temps de vidéo	Qualité de la vidéo	Audio	Prix
Veo 3.1	8s	1080p	Oui	1.25\$
Sora 2	15s	720p	Oui	0.20\$
Kling 3.0	15s	1080p	Oui	3.00\$
Wan 2.6	15s	1080p	Oui	1.575\$
Grok Imagine	15s	720p	Oui	0.20\$
Hailuo 2.3	10s	768p	Non	0.45\$

3.2.3 Pour un budget de 100\$

Modèle	Nombre de vidéos minimum	Nombre de vidéos maximum
Veo 3.1	333	80
Sora 2	571	500
Kling 3.0	1000	33
Wan 2.6	285	63
Grok Imagine	2000	500

Hailuo 2.3	666	222
-------------------	-----	-----

4 Exemple de prompt

A realistic identity verification style video. The person is centered in frame, facing the camera with neutral expression. After a short pause, they slowly turn their head to the left, then to the right, and return to the center. No speech. Consistent indoor lighting, plain background, clear facial visibility, natural blinking, no exaggerated movements.