



Département des Technologies de l'information et de la  
communication (TIC)  
Filière Informatique et systèmes de communication  
Orientation Sécurité informatique

**Rapport de recherche**

# **Génération d'images et de vidéos IA**

**Étudiant**

**Dylan Oliveira Ramos**

**Enseignant responsable**

Prof. Jean-Marc Bost

**Année académique**

2025-2026

Yverdon-les-Bains, le 26.03.2026

# 1 Introduction

Pour qu'un attaquant puisse modifier la photo d'une personne sur un document d'identité ou générer une vidéo d'une personne effectuant une vérification d'identité, il doit utiliser des modèles de génération d'images et de vidéos IA.

Ainsi, la solution la plus simple pour utiliser ces différents modèles est de passer par un service d'API. Un service d'API est une plateforme qui regroupe les APIs des différents services de génération. Il met à disposition une API qui permet d'utiliser plusieurs modèles d'IA de manière centralisée et moins coûteuse que chez les fournisseurs directement.

## 1.1 Kie.ai

Le service d'API choisi est [Kie.ai](#). Il a été choisi pour sa simplicité d'utilisation, sa documentation claire et son prix compétitif. De plus, il propose un « bac à sable » permettant de tester les APIs des modèles gratuitement et offre 80 crédits lors de l'inscription. C'est donc sur cette plateforme que vont se baser les chapitres suivants notamment pour les comparaisons de prix.

# 2 Génération d'images

Les modèles de génération d'images doivent être capables de générer des images réalistes de personnes fictives ainsi que de modifier des images existantes (vieillir une personne, modifier une photo d'identité, etc.). Il en existe deux catégories :

- Text-to-Image
- Image-to-Image

## 2.1 Text-to-Image

Les modèles de type Text-to-Image analysent le prompt et créent eux-mêmes les visuels à partir de zéro. Ils sont utiles pour générer des images de personnes fictives mais ne sont pas adaptés pour modifier des images existantes.

## 2.2 Image-to-Image

Les modèles de type Image-to-Image (édition d'images) partent d'une image fournie et la modifient en fonction du prompt. Ils sont utiles pour modifier des images existantes contrairement aux modèles de type Text-to-Image.

## 2.3 Tableaux comparatifs des modèles

Les modèles de génération d'images proposent généralement une version Text-to-Image et une version Image-to-Image, les tableaux ci-dessous concernent donc les deux types de modèles et présentent la qualité minimale et maximale d'image que chaque modèle peut générer avec les prix correspondants.

### Qualité minimale

| Modèle        | Qualité de l'image | Prix     |
|---------------|--------------------|----------|
| Nano Banana 2 | 1k                 | 0.04\$   |
| GPT Image 1.5 | 2k                 | 0.02\$   |
| Seedream 4.5  | 4k                 | 0.0325\$ |
| Grok Imagine  | 2k                 | 0.02\$   |

|               |    |        |
|---------------|----|--------|
| <b>Flux 2</b> | 1k | 0.07\$ |
|---------------|----|--------|

Qualité maximale

| Modèle               | Qualité de l'image | Prix     |
|----------------------|--------------------|----------|
| <b>Nano Banana 2</b> | 4k                 | 0.09\$   |
| <b>GPT Image 1.5</b> | 4k                 | 0.11\$   |
| <b>Seedream 4.5</b>  | 4k                 | 0.0325\$ |
| <b>Grok Imagine</b>  | 2k                 | 0.02\$   |
| <b>Flux 2</b>        | 2k                 | 0.12\$   |

### 3 Génération de vidéos

Les modèles de génération de vidéos doivent permettre de générer des vidéos réalistes de personnes effectuant une vérification d'identité (regarder la caméra, tourner la tête, sourire, etc.), il en existe trois catégories :

- Text-to-Video
- Image-to-Video
- Video-to-Video

#### 3.1 Text-to-Video et Image-to-Video

Les modèles de type Text-to-Video analysent le prompt et créent eux-mêmes les visuels et les mouvements à partir de zéro. Cela leur laisse beaucoup de créativité mais rend plus difficile le contrôle du résultat final, ce qui peut être problématique pour la vérification d'identité.

Les modèles de type Image-to-Video prennent généralement une image de début et une image de fin puis génèrent la séquence demandée dans le prompt. Ce type de modèle est plus contrôlable visuellement et est plus adapté à la vérification d'identité car il permet de faire correspondre le visage de la personne dans la vidéo avec celui sur les documents d'identité.

Comme pour les modèles de génération d'images, les modèles de génération de vidéos proposent généralement une version Text-to-Video et une version Image-to-Video avec les mêmes paramètres et les mêmes prix. C'est pourquoi les tableaux du [Chapitre 3.1.2](#) ne font pas de distinction entre ces deux types.

##### 3.1.1 Critères de sélection des modèles

Plusieurs modèles de génération de vidéos ont été analysés, les critères de sélection sont les suivants :

1. **Temps de vidéo** : la vidéo générée doit être suffisamment longue pour que la vérification de l'identité puisse se faire.
2. **Qualité de la vidéo** : la qualité de la vidéo doit être assez bonne pour tromper les systèmes de reconnaissance faciale.
3. **Audio** : la possibilité d'ajouter de l'audio est un plus.

##### 3.1.2 Tableaux comparatif des modèles

Les tableaux ci-dessous comparent les prix de chaque modèle dans leur configuration minimale (moins bonne qualité, plus courte durée, etc.) et maximale (meilleure qualité, durée plus longue, etc.).

**Prix minimum**

| Modèle              | Temps de vidéo | Qualité de la vidéo | Audio | Prix    |
|---------------------|----------------|---------------------|-------|---------|
| <b>Veo 3.1</b>      | 8s             | 1080p               | Oui   | 0.30\$  |
| <b>Sora 2</b>       | 10s            | 720p                | Oui   | 0.175\$ |
| <b>Kling 3.0</b>    | 3s             | 720p                | Non   | 0.10\$  |
| <b>Wan 2.6</b>      | 5s             | 720p                | Oui   | 0.35\$  |
| <b>Grok Imagine</b> | 6s             | 480p                | Oui   | 0.05\$  |
| <b>Hailuo 2.3</b>   | 6s             | 768p                | Non   | 0.15\$  |

**Prix maximum**

| Modèle              | Temps de vidéo | Qualité de la vidéo | Audio | Prix    |
|---------------------|----------------|---------------------|-------|---------|
| <b>Veo 3.1</b>      | 8s             | 1080p               | Oui   | 1.25\$  |
| <b>Sora 2</b>       | 15s            | 720p                | Oui   | 0.20\$  |
| <b>Kling 3.0</b>    | 15s            | 1080p               | Oui   | 3.00\$  |
| <b>Wan 2.6</b>      | 15s            | 1080p               | Oui   | 1.575\$ |
| <b>Grok Imagine</b> | 15s            | 720p                | Oui   | 0.20\$  |
| <b>Hailuo 2.3</b>   | 10s            | 768p                | Non   | 0.45\$  |

**3.2 Video-to-Video**

Les modèles de type Video-to-Video (édition de vidéos) modifient une vidéo fournie en fonction du prompt et d'une image de référence. Ils sont particulièrement utiles car ils permettent d'enregistrer une vidéo au préalable puis de remplacer la vraie personne par une autre personne.

À ce jour, le seul modèle de type Video-to-Video disponible sur Kie.ai est **Kling 3.0 motion control**. Les prix sont les suivants :

- Pour une vidéo en 720p : **0.10\$ par seconde**.
- Pour une vidéo en 1080p : **0.135\$ par seconde**.