



Département des Technologies de l'information et de la
communication (TIC)
Filière Informatique et systèmes de communication
Orientation Sécurité informatique

Rapport de recherche

Génération d'images et de vidéos IA

Étudiant

Dylan Oliveira Ramos

Enseignant responsable

Prof. Jean-Marc Bost

Année académique

2025-2026

Yverdon-les-Bains, le 25.03.2026

1 Introduction

Pour qu'un attaquant puisse modifier la photo d'une personne sur un document d'identité ou générer une vidéo d'une personne effectuant une vérification d'identité, il doit utiliser des modèles de génération d'images et de vidéos IA.

Ainsi, la solution la plus simple pour utiliser ces différents modèles est de passer par un service d'API. Un service d'API est une plateforme qui regroupe les APIs des différents services de génération. Il met à disposition une API qui permet d'utiliser plusieurs modèles d'IA de manière centralisée et moins coûteuse que chez les fournisseurs directement.

1.1 Kie.ai

Le service d'API choisi est Kie.ai. Il a été choisi pour sa simplicité d'utilisation, sa documentation claire et son prix compétitif. De plus, il propose un « bac à sable » permettant de tester les APIs des modèles gratuitement et offre 80 crédits lors de l'inscription. C'est donc sur cette plateforme que vont se baser les chapitres suivants notamment pour les comparaisons de prix.

2 Génération d'images

Les modèles de génération d'images doivent être capables de générer des images réalistes de personnes fictives ainsi que de modifier des images existantes (vieillir une personne, modifier une photo d'identité, etc.). Il en existe deux catégories :

- Text-to-Image
- Image-to-Image

2.1 Text-to-Image

Les modèles de type Text-to-Image analysent le prompt et créent eux-mêmes les visuels à partir de zéro. Ils sont utiles pour générer des images de personnes fictives mais ne sont pas adaptés pour modifier des images existantes.

2.2 Image-to-Image

Les modèles de type Image-to-Image (édition d'images) partent d'une image fournie et la modifient en fonction du prompt. Ils sont utiles pour modifier des images existantes contrairement aux modèles de type Text-to-Image.

2.3 Tableaux comparatifs des modèles

Les modèles de génération d'images proposent généralement une version Text-to-Image et une version Image-to-Image, les tableaux ci-dessous concernent donc les deux types de modèles et présentent la qualité minimale et maximale d'image que chaque modèle peut générer avec les prix correspondants.

Qualité minimale

Modèle	Qualité de l'image	Prix
Nano Banana 2	1k	0.04\$
GPT Image 1.5	2k	0.02\$
Seedream 4.5	4k	0.0325\$
Grok Imagine	2k	0.02\$

Flux 2	1k	0.07\$
---------------	----	--------

Qualité maximale

Modèle	Qualité de l'image	Prix
Nano Banana 2	4k	0.09\$
GPT Image 1.5	4k	0.11\$
Seedream 4.5	4k	0.0325\$
Grok Imagine	2k	0.02\$
Flux 2	2k	0.12\$

3 Génération de vidéos

Les modèles de génération de vidéos doivent permettre de générer des vidéos réalistes de personnes effectuant une vérification d'identité (regarder la caméra, tourner la tête, sourire, etc.), il en existe trois catégories :

- Text-to-Video
- Image-to-Video
- Video-to-Video

3.1 Text-to-Video et Image-to-Video

Les modèles de type Text-to-Video analysent le prompt et créent eux-mêmes les visuels et les mouvements à partir de zéro. Cela leur laisse beaucoup de créativité mais rend plus difficile le contrôle du résultat final, ce qui peut être problématique pour la vérification d'identité.

Les modèles de type Image-to-Video prennent généralement une image de début et une image de fin puis génèrent la séquence demandée dans le prompt. Ce type de modèle est plus contrôlable visuellement et est plus adapté à la vérification d'identité car il permet de faire correspondre le visage de la personne dans la vidéo avec celui sur les documents d'identité.

Ces deux types de modèles sont interchangeables, les vidéos ont donc les mêmes caractéristiques et le même prix, qu'elles soient générées à partir d'une image ou non. C'est pourquoi les tableaux du [Chapitre 3.1.2](#) s'appliquent à ces deux catégories.

3.1.1 Critères de sélection des modèles

Plusieurs modèles de génération de vidéos ont été analysés, les critères de sélection sont les suivants :

1. **Temps de vidéo** : la vidéo générée doit être suffisamment longue pour que la vérification de l'identité puisse se faire.
2. **Qualité de la vidéo** : la qualité de la vidéo doit être assez bonne pour tromper les systèmes de reconnaissance faciale.
3. **Audio** : la possibilité d'ajouter de l'audio est un plus.

3.1.2 Tableaux comparatif des modèles

Les tableaux ci-dessous comparent les prix de chaque modèle dans leur configuration minimale (moins bonne qualité, plus courte durée, etc.) et maximale (meilleure qualité, durée plus longue, etc.).

Prix minimum

Modèle	Temps de vidéo	Qualité de la vidéo	Audio	Prix
Veo 3.1	8s	1080p	Oui	0.30\$
Sora 2	10s	720p	Oui	0.175\$
Kling 3.0	3s	720p	Non	0.10\$
Wan 2.6	5s	720p	Oui	0.35\$
Grok Imagine	6s	480p	Oui	0.05\$
Hailuo 2.3	6s	768p	Non	0.15\$

Prix maximum

Modèle	Temps de vidéo	Qualité de la vidéo	Audio	Prix
Veo 3.1	8s	1080p	Oui	1.25\$
Sora 2	15s	720p	Oui	0.20\$
Kling 3.0	15s	1080p	Oui	3.00\$
Wan 2.6	15s	1080p	Oui	1.575\$
Grok Imagine	15s	720p	Oui	0.20\$
Hailuo 2.3	10s	768p	Non	0.45\$

3.2 Video-to-Video

Les modèles de type Video-to-Video (édition de vidéos) modifient une vidéo fournie en fonction du prompt et d'une image de référence. Ils sont particulièrement utiles car ils permettent d'enregistrer une vidéo au préalable puis de remplacer la vraie personne par une autre personne.

À ce jour, le seul modèle de type Video-to-Video disponible sur Kie.ai est **Kling 3.0 motion control**. Les prix sont les suivants :

- Pour une vidéo en 720p : **0.10\$ par seconde**.
- Pour une vidéo en 1080p : **0.135\$ par seconde**.

4 Exemple de prompt

A realistic identity verification style video. The person is centered in frame, facing the camera with neutral expression. After a short pause, they slowly turn their head to the left, then to the right, and return to the center. No speech. Consistent indoor lighting, plain background, clear facial visibility, natural blinking, no exaggerated movements.